

## 一种快速自适应遗传算法及其仿真研究

沐阿华<sup>1</sup>, 周绍磊<sup>2</sup>, 于晓丽<sup>3</sup>( <sup>1</sup> 海军航空工程学院研究生 2 队, 烟台 264001; <sup>2</sup> 海军航空工程学院自动控制系统, 烟台 264001; <sup>3</sup> 哈尔滨商业大学贸易经济学院, 哈尔滨 150028 )

**摘 要:** 遗传算法 (Genetic Algorithm, GA) 是一种模拟自然界生物进化过程与机制的一种优化搜索算法, 有着广泛的应用前景。但是, 简单遗传算法 (Simple Genetic Algorithm, SGA) 的收敛速度较慢, 稳定性差, 容易“过早收敛”。针对这些问题, 本文提出了相应的解决办法, 称为快速自适应遗传算法 (Fast Self-Adaptive Genetic Algorithm, FSAGA), 并通过仿真说明了算法的收敛快速性和全局收敛性都有了明显的改善。

**关键词:** 遗传算法; 收敛速度; 全局最优; 替代策略; 交叉和变异

**文章编号:** 1004-731X (2004) 01-0122-04 **中图分类号:** TP18 **文献标识码:** A

## Research on Fast Self-Adaptive Genetic Algorithm and Its Simulation

MU A-hua<sup>1</sup>, ZHOU Shao-lei<sup>2</sup>, YU Xiao-li<sup>3</sup>( <sup>1</sup> Graduate Brigade of NAEI, Yantai 264001, China; <sup>2</sup> Department of Automation, NAEI, Yantai 264001, China;<sup>3</sup> Institute of Trade and Economics, Harbin Commercial University, Harbin 150028, China)

**Abstract:** Genetic Algorithm (GA) is a general purpose stochastic optimization method for search problems, which is invented to mimic some of the processes and mechanisms observed in natural evolution. But Simple Genetic Algorithm's instinct deficiency like the unusually slow convergence, bad stability and easily-oriented prematurity has become the biggest obstacle for its further application. To solve the above problems, the corresponding solution—FSAGA (Fast Self-Adaptive Genetic Algorithm) is presented in this paper. Through simulation, it has shown that the convergent speed and global convergence are clearly improved.

**Keywords:** genetic algorithm; convergent speed; global optimization; replacement strategy; crossover and mutation

## 引 言

遗传算法 (GA) 是一类模拟生物进化过程与机制来求解问题的人工智能技术。70 年代初, J.H.Holland 把它创造性地应用于人工系统, 并成功解决了一些实际问题<sup>[1]</sup>。1989 年 D.J.Goldberg 对遗传算法及其应用作了全面且系统的论述<sup>[2]</sup>, 为遗传算法的理论和应用奠定了基础。由于遗传算法具有不依赖于问题模型的特性、全局最优性、隐含并行性及解决非线性问题的鲁棒性强等特点, 正越来越受到人们的重视。目前, 它已被广泛用于函数优化、图象处理、系统辨识、自动控制、经济预测和工程优化等领域<sup>[2][3]</sup>。

## 1 简单遗传算法

遗传算法与常规的优化和搜索方法的区别表现在以下几个方面<sup>[4]</sup>:

(1) GA 对种群字符串进行操作、并行搜索峰值。通过遗传操作来交换峰值间的信息, 降低在局部优化而非全局优化的可能性。

GA 只对参数集的编码进行操作, 而不是对参数本身。

(2) GA 仅仅需要评估目标函数值来引导搜索, 而不需要可微或其他附属信息。从系统仅仅能得到的反馈信息是当前种群的适配值。

(3) 转换规则是概率性的而不是确定性的, 每个字符串的适配值和它们如何比较都是随机性的, 即具有随机操作算子。

(4) 一个简单的遗传算法有复制、交叉和变异三种遗传操作算子<sup>[2]</sup>。

简单遗传算法的程序流程如图 1 所示。

众所周知, 简单的遗传算法 (SGA) 由于自身固有的缺陷, 通常优化过程的收敛速度慢, 容易存在一个“早熟”问题。

遗传算法研究的目标是使算法解的质量高, 又具有高的计算效率, 使其接近实用化。由于 SGA 是随机搜索, 要得到好的质量的解需要大量计算, 而另一方面片面追求搜索效率通常会导致早熟, 使解的质量降低<sup>[5]</sup>。如何解决收敛速度和解的质量之间的矛盾, 本文提出了一种快速自适应遗传算法 (FSAGA)。

## 2 快速自适应遗传算法

在遗传算法中, 收敛性主要由复制来实现, 而搜索性主要由交叉和变异来实现。所以, 不同的改进遗传算法都是在

收稿日期: 2003-04-01

修回日期: 2003-10-18

作者简介: 沐阿华 (1979-), 男, 江苏泰州, 硕士, 研究方向为测控系统、智能检测与故障检测、仿真软件工程等; 周绍磊 (1963-), 男, 山东淄博, 教授, 研究方向为飞行器自动测试系统、神经网络控制及应用等。于晓丽 (1979-), 女, 山东青岛, 汉, 硕士, 研究方向为经济与金融分析、数量经济技术研究等。

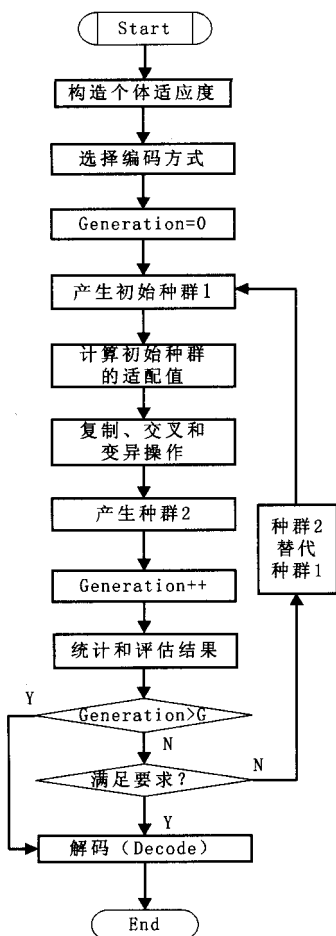


图1 简单遗传算法的程序流程

考虑复制、交叉和变异的策略。由于复制和交叉的作用, 适配值高的优良个体得到保留, 并且数量随着进化而不断增加, 最后可能在种群中出现大量的“近亲个体”, 产生“近亲繁殖”, 使进化停止, 过早收敛于局部值。而变异操作可以增加搜索空间, 扩大搜索范围, 有利于找到全局最优解, 但会影响收敛速度。FSAGA 有助于解决遗传算法存在的上述缺点, 并使算法更加接近于实际应用。

## 2.1 FSAGA 的机理

为了解决 GA 收敛速度和解的质量之间的矛盾 FSAGA 从以下几个方面着手。

### 2.1.1 初始种群的选定<sup>[6]</sup>

在简单 GA 和许多改进的 GA 中, 初始种群的产生采用完全随机方式, 这种方法不利于扩大搜索空间和搜索全局最优解。好的初始种群应是个体间保持一定的距离、有一定的差异, 尽量均匀地分布在解空间上。

假设: 种群的规模为  $N$ , 个体长度为  $L$ 。

定义: 广义海明距离  $GH$  是相同长度的以  $a$  为基的两个字符串  $i$  和  $j$  中对位不相同的数量。

所选初始种群应满足: 两两个体之间的广义海明距离  $GH_{ij} \geq \text{int}(bL)$ ,  $b$  视具体的情况而定。

因为  $N \ll a^{L - \text{int}(bL + 1)}$ , 所以能保证得到  $N$  个满足要求的个体。两个长度为  $L$  的字符串个体间的广义海明距离是  $GH$ , 这两个字符串中所包含的不相同的模式的数量是  $a^L - a^{L - GH}$ 。可见,  $GH$  越大, 字符串间所包含的不相同模式的数量就越多, 从而保证了个体的多样性, 避免产生早熟现象, 有利于搜索到全局最优。

### 2.1.2 适配值函数的选取

适配值函数是用来衡量各解优劣程度, 它的简单和复杂取决于问题的本身。对有些问题, 只需要一个数学解析公式; 有些问题不存在解析式, 需要一系列的规则来评价; 还有些问题, 需要这两者的结合。这里采用解析公式计算适配值, 在仿真实验中将具体说明。

### 2.1.3 替代策略和复制操作

为了保证个体的多样性, 有效防止早熟的产生, 我们采用以下替代策略:

(1) 父代和子代的  $N$  个个体的适配值从大到小排序。

(2) 对父子两代中排序相同的适配值大的前  $0.1N$  个个体, 保留两者中高适配值个体。

(3) 再将剩下的  $0.9N$  个个体, 按适配值从小到大排序。

设每个个体复制的数量为  $n_s^i (i=1, \dots, 0.9N)$ , 则有:

$$n_s^i = \text{int} \left( P_s^i \times 0.9N + 0.5 \right) \quad (1)$$

其中  $P_s^i (i=1, \dots, 0.9N)$  是每个个体复制的概率。

如各个体的适配值函数和相应的排序号分别为  $f_i$  和  $r_i (i=1, \dots, 0.9N)$ , 公式 (1) 还可以写成:

$$n_s^i = \text{int} \left( \frac{f_i}{\sum_{i=1}^{0.9N} f_i} \times 0.9N + 0.5 \right) \quad (2)$$

$$\text{或} \quad n_s^i = \text{int} \left( \frac{r_i}{\sum_{i=1}^{0.9N} r_i} \times 0.9N + 0.5 \right)$$

为了防止近亲繁殖, 当种群中个体间的广义海明距离  $GH_{ij} < k$  时, 就需要不断地引入新个体来随机地替代种群中的某些个体, 直到种群中个体间的广义海明距离  $GH_{ij} \geq k$ 。 $k$  为一常数, 一般取为 0.01。

### 2.1.4 交叉操作

交叉操作是对被选择复制的  $0.9N$  个个体进行的。如果它们之间的海明距离很小 (说明两个个体很相似), 此时应减少交叉作用或不进行, 即交叉操作概率很小或为 0, 以此来减少收敛时间。当两个个体之间的海明距离较大时, 交叉产生的新个体也就越多, 有助于提高搜索质量, 此时应采用较大的交叉操作概率。

$$P_c^{ij} = \begin{cases} 0 & a + \frac{(GH_{ij} - \overline{GH})}{\overline{GH}} < 0 \\ a + \frac{(GH_{ij} - \overline{GH})}{\overline{GH}} & 0 \leq a + \frac{(GH_{ij} - \overline{GH})}{\overline{GH}} \leq 1 \\ 1 & a + \frac{(GH_{ij} - \overline{GH})}{\overline{GH}} > 1 \end{cases} \quad (3)$$

交叉操作概率  $P_c$  具有如下形式：

式中  $i, j$  为种群中的两个个体； $GH_{ij}$  为两者的广义海明距离； $\overline{GH}$  为种群中所有个体间的平均广义海明距离；

### 2.1.5 变异操作

当种群中的两个个体间的最大广义海明距离  $GH_{\max}$  与平均广义海明距离  $\overline{GH}$  接近以及种群中所有个体的最大适配值  $f_{\max}$  与平均适配值  $\bar{f}$  接近时，说明种群已基本趋于一致，可能导致进化停滞，过早地收敛，此时应采用大变异操作<sup>[7]</sup>，来改变这种情况。

综合考虑按如下变异概率  $P_m$  进行变异操作：

$$P_m = \frac{b}{I_1(f_{\max} - \bar{f}) + I_2(GH_{\max} - \overline{GH})} \quad (4)$$

式中  $f_{\max}$ 、 $\bar{f}$ 、 $GH_{\max}$ 、 $\overline{GH}$  分别表示种群中所有个体的最大适配值、平均适配值、两个个体间的最大广义海明距离、平均广义海明距离。 $I_1, I_2$  和  $b$  为常数，视具体情况而定。

至此，种群中  $0.1N$  个体经过替代和  $0.9N$  个体经过复制、交叉和变异操作后，产生了新一代的种群。

### 2.1.6 迭代停止条件

如果在  $G$  代内，最优适配值没有明显的提高，则迭代停止，解码输出结果。一般强制停止条件为  $G=N/3$ 。

## 2.2 FSAGA 的仿真实例

快速自适应遗传算法的程序流程如图 2 所示。

程序采用 C/C++ 编写，主要是根据 David, E. Goldberg 的 Pascal 源程序改写。

### 2.2.1 选用典型函数最优化测试<sup>[8]</sup>

待优化函数

$$\min H = \min \sum_{i=1}^3 x_i^2 \quad (5)$$

算法实现

每个变量用 8 位的二进制数表示，把三个变量的二进制码串成一个个体，所以编码长度  $L=24$ ，种群大小  $N=3L=72$ ，强制结束进化代数  $G=N/3=24$ 。

适配值函数

$$f(x_i) = \frac{1}{H(x_i) + 1} \quad (6)$$

仿真结果分析

分别用简单遗传算法、均匀交换遗传算法<sup>[8]</sup>和快速自适应遗传算法进行仿真，将仿真 20 次的结果取平均值记录于表 1，从中可以看到快速自适应遗传算法不仅收敛速度快，而且能得到更优越的解。

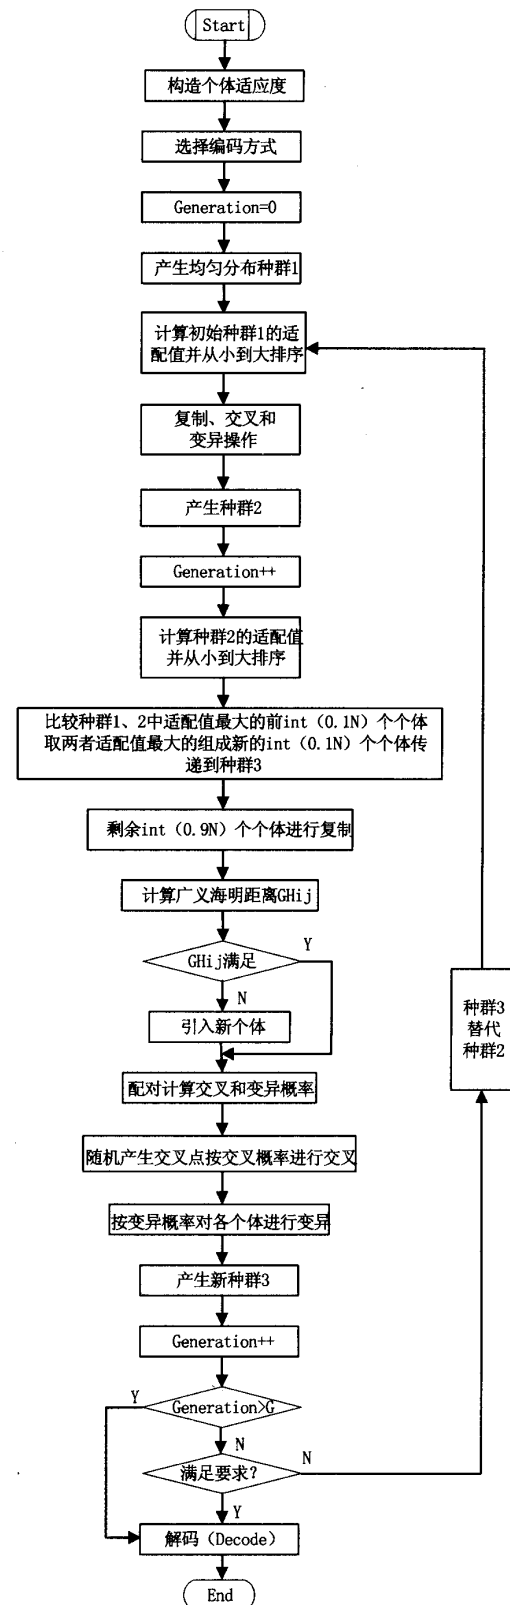


图 2 快速自适应遗传算法的程序流程

表 1 几种遗传算法达到指定函数值的进化代数

优化函数值	1	0.5	0.1	0.05	0.01	0.005	0.001
简单遗传算法	3	8	30	45	185	—	—
均匀交换遗传算法	3	8	54	90	157	—	—
快速自适应遗传算法	2.6	4.5	8.4	11.6	39	46	51

注: “—”表示进化代数超过 200 代仍达不到指定值。

## 2.2.2 背包问题<sup>[9]</sup>求解

背包问题 (Knapsack problem), 是一个典型的 NP 完全问题, 主要应用于管理中的资源分配、投资决策、装载问题的建模。其主要依靠一些启发式算法 (如贪心算法), 但只能得到近似最优解, 不能保证一定能够得到最优解, 遗传算法也可解决这类问题。

### 问题描述

背包问题的数学模型是一个 0-1 规划问题。假设有  $n$  个物件, 其重量用  $a_i$  表示, 价值为  $c_i$  ( $i=1, \dots, n$ ), 背包的最大容纳重量为  $b$ 。如果物件  $i$  被选入背包时, 定义变量  $x_i=1$ , 否则  $x_i=0$ 。考虑在背包容纳重量允许下, 如何决定变量  $x_i$  ( $i=1, \dots, n$ ) 的值使背包内物件的总价值最大。总组合数为  $2^n$  个, 数学模型表示为:

$$\begin{cases} \text{Max} J = \sum_{i=1}^n c_i x_i \\ \text{st.} \quad \sum_{i=1}^n a_i x_i \leq b \\ x_i = 0 \text{ 或 } 1, i = 0, \dots, n \end{cases} \quad (7)$$

上式中,  $c_i, a_i, b$  均为正值。

### 算法实现

采用二进制编码, 一组 0-1 决策变量  $x_i$  ( $i=1, \dots, n$ ) 直接表示成  $n$  维二进制串, 构成一个个体。若第  $i$  位基因码为 1, 则表示第  $i$  个物件被选入背包。若第  $i$  位基因码为 0, 则表示第  $i$  个物件不被选入背包。

### 适配值函数

采用罚函数法计算适配值函数, 公式如下:

$$f(x_i) = \begin{cases} \sum_{i=1}^n c_i x_i, & \sum_{i=1}^n a_i x_i \leq b \\ 0, & \sum_{i=1}^n a_i x_i > b \end{cases} \quad (8)$$

### 仿真模拟

问题规模为 50 个变量, 种群数为 50, 终止代数为 500。

列举 5 个背包问题, 它们的系数  $c_i, a_i$  在区间  $[0, 999]$  内随机产生。

$$0.5 \sum_{i=1}^{50} a_i$$

$b$  的值按计算, 必须满足

$a_i \leq b$  ( $i = 1, \dots, 50$ ), 否则重新产生系数。

### 结果分析

利用简单遗传算法和快速自适应遗传算法分别计算末世代的目标函数值, 将它们和用分枝定界法<sup>[9]</sup>获得的精确解比较得到相对误差。对 5 个不同背包问题分别计算, 得到表 2 所示的比较结果。

表 2 SGA 和 FSAGA 计算结果比较

末世代目标函数值相对误差	SGA	FSAGA
问题 1	0.033	0.000
问题 2	0.082	0.020
问题 3	0.076	0.003
问题 4	0.104	0.009
问题 5	0.043	0.001

从表中可看出, 快速自适应遗传算法比简单遗传算法优化的效果要好得多。

## 3 结论 (Conclusion)

通过上面的分析和仿真实验结果可以看出, 快速自适应遗传算法采用以下策略: 首先初始种群不是采取完全随机的方式产生的, 采用适应问题解空间分布状况的初始种群, 保证了个体模式的合理分布; 其次通过保护优秀个体和比较父子个体的优劣, 更有效地保留个体中信息, 通过引进新种群, 解决了种群中个体多样性的问题; 再者采用自适应的方式确定各个体的交叉概率和变异概率。实验证明快速自适应遗传算法具有解的质量高和良好的计算速度的特点, 更适合于工程实际问题的优化。

### 参考文献:

- [1] John Holland. Adaptation in Natural and Artificial System[M]. Ann Arbor: University of Michigan Press, 1975.
- [2] Goldberg David E. Genetic Algorithm in search, Optimization and Machine Learning[M]. Reading, MA: Addison-Wesley, 1989.
- [3] L. Davis. Handbook of Genetic Algorithms[M]. New York: Van Nostrand Reinhold, 1991.
- [4] Chin-Teng Lin, Chong-Ping Jou. Controlling Chaos by GA-Based Reinforcement Learning Neural Network[J]. IEEE Trans. Neural Networks, 1999, 10(4): 846-859.
- [5] De Jong K A. An Analysis of the Behavior of a Class of Genetic Adaptive Systems[D]. University of Michigan, 1975.
- [6] 李兵, 谢剑英. 遗传算法的自适应代沟的替代策略研究[J]. 控制理论与应用, 2001, 18(1): 41-44.
- [7] 吴斌, 吴坚. 快速遗传算法研究[J]. 电子科技大学学报, 1999, 28(1): 49-52.
- [8] 马钧水, 刘贵忠. 改进遗传算法搜索性能的大变异操作[J]. 控制理论与应用, 1998, 15(3): 404-408.
- [9] 钱颂迪, 等. 运筹学[M]. 北京: 清华大学出版社, 1999.